

$$1) \quad t_n = \phi(\mathbf{x}_n) \mathbf{w}^T + \eta_n$$

con  $\{t_n \in \mathbb{R}, \mathbf{x}_n \in \mathbb{R}^P\}_{n=1}^N, \mathbf{w} \in \mathbb{R}^Q$

$$\phi: \mathbb{R}^P \rightarrow \mathbb{R}^Q$$

$$Q \geq P$$

$$\eta_n \sim N(\eta_n | 0, \sigma_n^2)$$

$$t_n = \Phi \mathbf{w} + \eta_n \quad \therefore \Phi \in \mathbb{R}^{N \times Q}, \eta \sim N(0, \sigma^2 \mathbf{I})$$

### Mínimos Cuadrados

$$\min_{\mathbf{w}} J(\mathbf{w}) = \frac{1}{2} \|t - \Phi \mathbf{w}\|_2^2$$

### Solución Mínimos Cuadrados

$$J(\mathbf{w}) = \frac{1}{2} (t - \Phi \mathbf{w})^T (t - \Phi \mathbf{w})$$

$$J(\mathbf{w}) = \frac{1}{2} (t^T t - 2 \mathbf{w}^T \Phi^T t + \mathbf{w}^T \Phi^T \Phi \mathbf{w})$$

$$\frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} = \frac{1}{2} (-2 \Phi^T t + 2 \Phi^T \Phi \mathbf{w}) = 0$$

$$= \Phi^T t + \Phi^T \Phi \mathbf{w}$$

$$\Phi^T \Phi \mathbf{w} = \Phi^T t$$

$$\mathbf{w}^* = \underbrace{(\Phi^T \Phi)^{-1}}_{\mathbf{P}} \Phi^T t$$

Invertible

## Mínimos cuadrados regularizados

$$\min_w J_\lambda(w) = \frac{1}{2} \|t - \Phi w\|_2^2 + \frac{1}{2} \lambda \|w\|_2^2$$

## Solución mínimos cuadrados regularizados

$$J_\lambda(w) = (t - \Phi w)^T (t - \Phi w) + \lambda w^T w$$

$$J_\lambda(w) = t^T t - 2 w^T \Phi^T t + w^T \Phi^T \Phi w + \lambda w^T w$$

$$\frac{\partial J_\lambda(w)}{\partial w} = \frac{1}{2} \left[ -2 \Phi^T t + 2 \Phi^T \Phi w + 2 \lambda w \right] = 0$$

$$= -\Phi^T t + \Phi^T \Phi w + \lambda w = 0$$

$$\Phi^T \Phi w + \lambda w = \Phi^T t$$

$$(\Phi^T \Phi + \lambda I)w = \Phi^T t$$

$$w^* = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T t$$

## Máxima verosimilitud

$$t_n = \phi(x_n) w^T + \eta_n$$

$$p(t_n | x_n, w, \sigma_n^2) = N(t_n | \phi(x_n) w^T, \sigma_n^2)$$

Para los datos  $\{(x_n, t_n)\}_{n=1}^N \therefore \text{i.i.d}$

$$p(t | \Phi, W, \Sigma_n^2) = \prod_{n=1}^N N(t_n | \Phi(x_n)W^T, \Sigma_n^2)$$

$$\log p(t | \Phi, W, \Sigma_n^2) = -\frac{N}{2} \log (2\pi \Sigma_n^2) - \frac{1}{2\Sigma_n^2} \|t - \Phi w\|^2$$

Solución máxima verosimilitud

$$\max_w \log p(t | \Phi, W, \Sigma_n^2) \Rightarrow \min_w \|t - \Phi w\|^2$$

Máximo a posteriori

$$p(t | \Phi, W, \Sigma_n^2) = N(t | \Phi w, \Sigma_n^2 I)$$

$$p(t | \Phi, W) = \frac{1}{(2\pi \Sigma_n^2)^{N/2}} \exp \left( -\frac{1}{2\Sigma_n^2} \|t - \Phi w\|^2 \right)$$

Prior gaussiano

$$p(W) = N(W | 0, \alpha^{-1} I) = \frac{\alpha^{Q/2}}{(2\pi)^{Q/2}} \exp \left( -\frac{\alpha}{2} W^T W \right)$$

Bayes

$$p(W | t, \Phi) = \frac{p(t | \Phi, W) p(W)}{p(t | \Phi)}$$

$$p(W | t, \Phi) = \exp \left( -\frac{1}{2\Sigma_n^2} \|t - \Phi w\|^2 \right) \exp \left( -\frac{\alpha}{2} W^T W \right)$$

$$\therefore p(W | t, \Phi) = \frac{1}{\sqrt{(2\pi)^Q \det(\Sigma_n^2) \alpha^Q}} \exp \left( -\frac{1}{2\Sigma_n^2} \|t - \Phi w\|^2 - \frac{\alpha}{2} W^T W \right)$$

$$\log \mathcal{L}(w, t, \Psi) = -\frac{1}{2\sigma_n^2} \|t - \Psi w\|^2 - \frac{\alpha}{2} w^T w + C$$

Agrupa las constantes que no dependen de  $w$

$$J(w) = \frac{1}{2\sigma_n^2} \|t - \Psi w\|^2 + \frac{\alpha}{2} w^T w$$

Multiplico por  $2\sigma_n^2$  para simplificar

$$\hat{J}(w) = \|t - \Psi w\|^2 + \lambda w^T w \quad \therefore \lambda = \alpha \sigma_n^2$$

$$\hat{J}(w) = t^T t - 2w^T \Psi^T t + w^T \Psi^T \Psi w + \lambda w^T w$$

↓

Lleva a la solución de mínimos cuadrados regularizados

## Regresión Rígida Kernel

$$t_n = \phi(x_n) w^T + \eta_n$$

función Kernel

$$K(x_n, x_m) = \langle \phi(x_n), \phi(x_m) \rangle$$

$$t = K w + \eta$$

$$J(w) \approx \frac{1}{2} (\|t - K w\|^2 + \lambda w^T w)$$

$$J(W) = t^T t - 2W^T Kt + W^T K^T K W + \lambda W^T K W$$

$$\begin{aligned}\frac{\partial J(W)}{\partial W} &= -2Kt + 2K^T KW + 2\lambda KW = 0 \\ &= -2Kt + 2(K^T K + \lambda K)W = 0 \\ &= (K^T K + \lambda K)W = Kt\end{aligned}$$

### Solución Regresión Rígida Kernel

$$W^* = (K^T K + \lambda K)^{-1} Kt$$

Regresión con procesos gaussianos

$$t_n = f(x_n) + \eta_n$$

↓  
Modelo mis  
datos

$$f(x) \sim GP(m(x), K(x, x'))$$

$m(x) \rightarrow$  media del proceso en  $x$  ( $m(x) = 0$ )

$K(x, x') \rightarrow$  función de covarianza

$$K(x_n, x_m) = \text{cov}(f(x_n), f(x_m))$$

Distribución conjunta de las observaciones

$$\begin{pmatrix} f \\ t \end{pmatrix} \sim N \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} K(x, x) + \sigma_n^2 I & K(x, x_*) \\ K(x_*, x) & K(x_*, x_*) + \sigma_n^2 I \end{pmatrix} \right)$$

$X \rightarrow$  Matriz entrenamiento

$y \rightarrow$  vector respuesta

$X_* \rightarrow$  conjunto para predicción

$K(\alpha, \beta) \rightarrow$  Matriz de covarianzas

Condicional de la distribución del posterior

$$p(f_* | X, t, X_*) = N(\mu_*, \Sigma_*)$$

Solución regresión mediante procesos gaussianos

$$\mu_* = K(X_*, X)(K(X, X) + \sigma_n^2 I)^{-1} t$$

$$\Sigma_* = K(X_*, X_*) - K(X_*, X)(K(X, X) + \sigma_n^2 I)^{-1} K(X, X_*)$$